

Propuesta de Implementación: Análisis de Sentimientos en Reseñas de Telefonía Móvil

Este documento detalla la arquitectura, metodología y justificación técnica para la implementación de un sistema de análisis de sentimientos basado en léxico. El proyecto utilizará el conjunto de datos de reseñas de teléfonos móviles de Amazon, con el objetivo de clasificar la polaridad de las opiniones de los usuarios y extraer valor analítico sobre la percepción de los productos.

1. Ingesta del Dataset

La fase inicial establece la base de datos para el procesamiento analítico, asegurando la integridad y la calidad de la información desde el primer paso.

- **Extracción y Carga (ETL):** El dataset se importará utilizando librerías de manipulación de datos de alto rendimiento (como Pandas). Dado el volumen potencial de las reseñas de Amazon, se implementará una lectura eficiente optimizando los tipos de datos en memoria.
- **Exploración Inicial (EDA):** Se realizará un perfilado de los datos para identificar la distribución de calificaciones (1 a 5 estrellas), la longitud promedio de las reseñas y la proporción de valores nulos o atípicos.
- **Limpieza Estructural:** Eliminación de registros duplicados (spam o re-envíos de usuarios) y descarte de filas que carezcan de texto en la columna principal de la reseña o que no posean una calificación asociada, ya que esta última servirá como *ground truth* (verdad fundamental) para la validación.

2. Preprocesamiento de Texto (Pipeline NLP)

El análisis basado en léxico es altamente sensible al "ruido" en el texto. Se construirá un pipeline robusto de Procesamiento de Lenguaje Natural (NLP) para estandarizar el corpus antes de la puntuación.

Fase del Pipeline	Descripción Técnica	Impacto en el Análisis
Normalización	Conversión a minúsculas, manejo de codificación UTF-8 y expansión de contracciones (ej. "don't" a "do not").	Evita que el algoritmo trate "Battery" y "battery" como entidades distintas.
Limpieza de Ruido	Uso de expresiones regulares (Regex) para eliminar URLs, etiquetas HTML residuales y caracteres especiales no semánticos.	Reduce la dimensionalidad del texto y evita falsos positivos en el diccionario.
Filtrado Selectivo	Eliminación de <i>Stopwords</i> (palabras vacías) mediante diccionarios estándar, conservando explícitamente palabras de negación ("no", "never").	Acelera el procesamiento sin perder el contexto crítico de la inversión de polaridad.
Lematización	Reducción morfológica de las palabras a su raíz utilizando herramientas como spaCy o NLTK.	Maximiza la tasa de coincidencia (match rate) entre las reseñas y el léxico elegido.

3. Selección de Léxico: Justificación de VADER

Para este contexto de comercio electrónico, se propone el uso exclusivo de **VADER (Valence Aware Dictionary and sEntiment Reasoner)**. Frente a alternativas más simples como Bing Liu o AFINN, VADER ofrece ventajas algorítmicas críticas para reseñas de productos:

- **Sensibilidad a la Intensidad (Heurística):** VADER puntúa matemáticamente el uso de mayúsculas ("GREAT" vs "great") y signos de puntuación ("bad!!!" vs "bad"), elementos omnipresentes en las opiniones de consumidores.

- **Manejo de Negaciones y Conjunciones:** Identifica estructuras como "no es bueno" e invierte el puntaje automáticamente. Además, entiende que la conjunción "pero" (but) cambia el peso del sentimiento de la oración hacia la cláusula final.
- **Puntuación Compuesta:** Retorna un *Compound Score* normalizado entre -1.0 y +1.0, lo que permite establecer umbrales matemáticos claros para la categorización.

3.1. Estrategia de Adaptación al Dominio (Domain-Specific Tuning)

Para aumentar la precisión en reseñas tecnológicas, el diccionario estándar de VADER será actualizado dinámicamente inyectando terminología específica de telefonía móvil.

Ejemplo de inyección léxica para contexto de hardware/software

```
nuevas_palabras = {
    'bloatware': -2.5,
    'lag': -2.5,
    'ladrillo': -3.0, # Contexto: "bricked"
    'caliente': -2.0,
    'fluido': 2.5,
    'nitidez': 2.0
}
vader_analyzer.lexicon.update(nuevas_palabras)
```

4. Metodología de Análisis y Validación

Una vez calculada la polaridad de cada reseña, el proyecto no se limitará a la asignación de etiquetas, sino que ejecutará una validación estadística profunda.

1. **Clasificación por Umbrales:** Se agruparán los resultados utilizando el *compound score*:
 - Positivo: $\text{Score} \geq 0.05$
 - Neutral: $-0.05 < \text{Score} < 0.05$
 - Negativo: $\text{Score} \leq -0.05$
2. **Contraste con la Verdad Fundamental (Ground Truth):** Se mapearán las calificaciones originales de Amazon (1-5 estrellas) a categorías equivalentes (Ej. 1-2 negativas, 3 neutral, 4-5 positivas) para comparar las predicciones del modelo.
3. **Métricas de Evaluación:** Se calcularán métricas estándar de clasificación, incluyendo Matriz de Confusión, Precisión (Accuracy), Recall y el F1-Score, para entender en qué tipo de comentarios falla el sistema (ej. detección pobre de sarcasmo).

5. Conclusión e Impacto Analítico

La implementación exitosa de este flujo de trabajo permitirá transformar datos no estructurados (texto libre) en métricas de negocio cuantificables. El uso de VADER, complementado con una inyección léxica adaptada al dominio tecnológico, garantiza una precisión superior a la de los diccionarios tradicionales.

Como entregables finales, el análisis permitirá generar visualizaciones o tableros de control que identifiquen los puntos críticos (*pain points*) más frecuentes reportados por los usuarios, como problemas de batería o rendimiento, facilitando la toma de decisiones informadas sobre el ciclo de vida de los dispositivos evaluados.